

## 2.1 Hard- & Soft-SVM

Based on Lecture 2 and Recitation 4

In class we saw the Hard-SVM classification model.

1. Prove that the following Hard-SVM optimization problem is a Quadratic Programming problem:

$$\arg \min_{(w,b)} \|w\|^2 \quad \text{s.t.} \quad \forall i, y_i((w, x_i) + b) \geq 1 \quad (1)$$

That is, find matrices  $Q$  and  $A$  and vectors  $a$  and  $d$  such that the above problem can be written in the following format

$$\arg \min_{v \in \mathbb{R}^d} v^T Q v + a^T v \quad \text{s.t.} \quad A v \leq d \quad (2)$$

Hint: Observe that  $\|w\|^2 = w^T I w$

$$\arg \min_{(w,b)} \|w\|^2 \Leftrightarrow \arg \min_{(w,b)} \left\| \begin{pmatrix} w \\ b \end{pmatrix} \right\|^2$$

$$\Rightarrow \arg \min_{(w,b)} \begin{pmatrix} w \\ b \end{pmatrix}^T I \begin{pmatrix} w \\ b \end{pmatrix}$$

הבעיה היא

$$\text{s.t. } y_i (\langle w, x_i \rangle + b) \geq 1$$

$$\Leftrightarrow -y_i x_i^T w - y_i b \leq -1 \quad \forall i$$

$$\Rightarrow \begin{pmatrix} -y_1 x_1^T & -y_1 \\ \vdots & \vdots \\ -y_n x_n^T & -y_n \end{pmatrix} \cdot \underbrace{\begin{pmatrix} w \\ b \end{pmatrix}}_v \leq \underbrace{-1}_d$$

$A \in \mathbb{R}^{m \times (d+1)}$

$$v = \begin{pmatrix} w \\ b \end{pmatrix}$$

$$a^T \begin{pmatrix} w \\ b \end{pmatrix} + \frac{1}{2} \begin{pmatrix} w \\ b \end{pmatrix}^T Q \begin{pmatrix} w \\ b \end{pmatrix} = w^T I w \quad (2)$$

הבעיה היא  $a=0$  ו- $d$  היא וקטור של 1

$$Q_{ij} = \begin{cases} 1 & i=j \wedge i \leq d \\ 0 & \text{else} \end{cases}$$

כלומר מטריצה מהצורה

$$\begin{pmatrix} \frac{1}{2} & 0 & \dots & 0 \\ 0 & \ddots & & \\ \vdots & & \ddots & \\ 0 & \dots & 0 & \frac{1}{2} \end{pmatrix}$$

עבורה מתקיים

$$a^T \begin{pmatrix} w \\ b \end{pmatrix} + \frac{1}{2} \begin{pmatrix} w \\ b \end{pmatrix}^T Q \begin{pmatrix} w \\ b \end{pmatrix} = \frac{1}{2} w^T 2I w = w^T I w = \|w\|^2$$

בנקודה.

$$Q \in \mathbb{R}^{m \times m}$$

$$\arg \max_{k \in [K]} \frac{f_{x|y=k}(x) f_Y(k)}{f_X(x)} \quad (a)$$

$$= \arg \max_{k \in [K]} f_{x|y=k}(x) f_Y(k)$$

$$= \arg \max_{k \in [K]} \mathcal{L}_k \cdot N(x | \mu_k, \sigma_k^2)$$

$$\arg \max_{k \in [K]} \mathcal{L}_k \cdot \frac{1}{\sqrt{2\pi\sigma_k^2}} \exp\left(-\frac{(x - \mu_k)^2}{2\sigma_k^2}\right)$$

317'87"  $\pi$   $\delta$   $\epsilon$

$$\mathcal{L}(\mathcal{D} | X, Y) = P_{X, Y | \mathcal{D}}(X_i, Y_i)_{i=1}^m$$

$$= \prod_i P_{X, Y | \mathcal{D}}(X_i, Y_i)$$

$$= \prod_i P_{X, Y | \mathcal{D}}(X) P_{Y | \mathcal{D}}(Y_i)$$

$$= \prod_i N(X | \mu_{Y_i}, \sigma_{Y_i}^2) \mathcal{M}(Y_i | \mathcal{D})$$

$$= \prod_{i=1}^m \frac{1}{\sqrt{2\pi\sigma_{Y_i}^2}} \exp\left(-\frac{(X - \mu_{Y_i})^2}{2\sigma_{Y_i}^2}\right) \cdot \mathcal{L}_{Y_i}$$

$$= \left(\prod_i \mathcal{L}_{Y_i}\right) \cdot \left(\frac{1}{\sqrt{2\pi\sigma_{Y_i}^2}}\right)^m \exp\left(\sum_{i=1}^m \frac{(X - \mu_{Y_i})^2}{2\sigma_{Y_i}^2}\right)$$

נרצה למצוא את התקסימום ובנוסף  $\log$  הכול  
 מינימליזציה של התקסימום של  $\log$  הכול  
 למקסימום של הליקיוז.

$$\begin{aligned} \log(L(\theta | x, y)) &= \log\left(\prod_i \pi_{y_i}\right) - \frac{m}{2} \log(2\sigma_{y_i}^2) \\ &\quad + \sum_{i=1}^m -\frac{(x - \mu_{y_i})^2}{2\sigma_{y_i}^2} \\ &= \sum_{i=1}^m \left( -\frac{1}{2} \log(2\sigma_{y_i}^2) - \frac{(x - \mu_{y_i})^2}{2\sigma_{y_i}^2} + \log(\pi_{y_i}) \right) \end{aligned}$$

נמצא לבי  $\sigma_{y_i}, \pi_{y_i}$  - אפשר לראות לבי כולם למצוא

סדר נקודה לבי התחלה

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i: y_i = k} x_i \quad \hat{\sigma}_k^{MS} = \frac{n_k}{m} \Rightarrow h_k = \hat{\sigma}_k m$$

$$\hat{\sigma}_k = \frac{1}{n_k} \sum_{i: y_i = k} (x_i - \hat{\mu}_k^{MS})^2$$

ה. עבור  $x \in \mathbb{R}^d$  נקודה  $x$  ו  $k$  של מטר

$$x \sim N(\mu_{x_j}, \sigma_{x_j}^2) \quad \text{בצורה הבאה}$$

מכיוון שהמשתנים הם ב"ת נקרא שהתפלגות

המשתנה היא המפלגה של התפלגויות

$$\hat{y} = \underset{k \in K}{\operatorname{argmax}} \left( \pi_k \cdot \prod_{d=1}^d N(x_{d,j}, \mu_{k,j}, \sigma_{k,j}^2) \right) \quad | \text{כפ}$$

$$= \prod_{j=1}^d \underset{k \in K}{\operatorname{argmax}} \left( \pi_k \cdot N(x_{d,j}, \mu_{k,j}, \sigma_{k,j}^2) \right)$$

האיות אופן נקרא ל

$$\begin{aligned} \mathcal{L}(\theta|x,y) &= \prod_{j=1}^d \left( \prod_{i=1}^m f_{x,y=y_i|\theta}(x_{d,i}) \cdot \pi_{y_i} \right) \\ &= \prod_{d=1}^d \cdot \left( \prod_{i=1}^m \pi_{y_i} \right) \left( 1/(2\sqrt{\sigma_{d,y_i}^2}) \right)^m \exp \left( \sum_{i=1}^m \frac{(x_{d,i} - \mu_{d,y_i})^2}{2\sigma_{d,y_i}^2} \right) \end{aligned}$$

$\Rightarrow$

ל"ס ו"ס האיות י"ס

$$\log(\mathcal{L}(\theta|x,y)) = \sum_{j=1}^d \left( \sum_{i=1}^m \pi_{y_i} + \sum_{i=1}^m f_{x_{ij}}(x_{ij}) \right)$$

$\leq \leq$  נ"ס ו"ס נ"ס א"ס  $\mu_k, \hat{\sigma}_k$  א"ס נקרא

ס"ס ס"ס נ"ס

$$\pi_k = \frac{n_k}{m}$$

$$\mu_{k,j} = \frac{\sum_{i=1}^m \prod_{y_i=k} x_{ij}}{n_k}$$

$$\hat{\sigma}_k = \frac{1}{n_k} \sum_{i=1}^m \prod_{(y_i=k)} (x_{ij} - \mu_{k,j})^2$$

$$\arg \max_{k \in [K]} \frac{f_{X|Y=k}(x) f_Y(k)}{f_X(x)}$$

$$= \arg \max_{k \in [K]} f_{X|Y=k}(x) f_Y(k)$$

$$= \arg \max_{k \in [K]} \sigma_k \cdot \text{Poi}(n_k)$$

$$\arg \max_{k \in [K]} \sigma_k \cdot \left( \frac{n_k}{k!} e^{-n_k} \right)$$

$y \sim \text{Multinomial}(\pi)$

$x_j | y = k \stackrel{\text{ind.}}{\sim} \text{Poi}(\lambda_{kj})$

2

$$L(\Theta | x, y) = p_{x, y | \Theta} \left( \sum_{i=1}^m x_i, y_i \mid \{_{i=1}^m \right)$$

הסתברות של  $x$  ו- $y$

$$= \prod_{i=1}^m f_{x, y | \Theta} (x_i, y_i)$$

$$= \prod_{i=1}^m f_{x=y_i | \Theta} (x) \cdot f_{y | \Theta} (y_i)$$

$$= \prod_{i=1}^m \sigma_{y_i} \cdot \frac{n_{y_i}^{x_i} e^{-n_{y_i}}}{x_i!}$$

לוקחים את  $\log$

לוקחים את  $\log$

$$\Rightarrow \log(L(\Theta | x, y)) \approx \sum_{i=1}^m \left( (\log(\sigma_{y_i})) + x_i \log(n_{y_i}) - n_{y_i} - (i \ln(i) - i) \right)$$

$$\Rightarrow \sum_{i=1}^m \left( (\log(\sigma_{y_i})) + x_i \log\left(\frac{n_{y_i}}{x_i}\right) - n_{y_i} + x_i \right)$$

נמצא מקסימום בעזרת כושר דיפרנציאציה.

$$\frac{\partial}{\partial n_k} = 0 = \frac{n_k}{n} - 1 \rightarrow \hat{n}_k = \frac{n_k}{1} = \frac{n_k}{m}$$

$$\Rightarrow 1 = \sum_{k=1}^m n_k = \sum \frac{n_k}{n} \rightarrow \boxed{n=m}$$

$$n_k = \frac{n_k}{m}$$

$$\frac{\partial}{\partial n_k} = 0 = \sum_{i=1}^m \frac{x_i}{n_{y_i}} - 1 \rightarrow \left( \begin{array}{c} \text{קטגורי} \\ \text{רציפי} \\ y_i = k \end{array} \right)$$

$$\Rightarrow \left( \sum_{i=1}^m x_i \right) / n_k = n_k = 0$$

$$\Rightarrow \hat{n}_k = \frac{\sum_{i=1}^m \prod_{y_i=k} (x_i)}{n_k}$$

ה. כמו בעמוד קודם נסיק שמהדר בכל של התפלגויות.  
 שכן נקבל  $\log e$  הנראות הינו מהצורה:

$$\sum_{j=1}^d \sum_{i=1}^m \left( (\log(n_{y_i})) + x_{ij} \log\left(\frac{n_{y_i}}{x_{ij}}\right) - n_{y_i} + x_{ij} \right)$$

סידור נקבל את זה

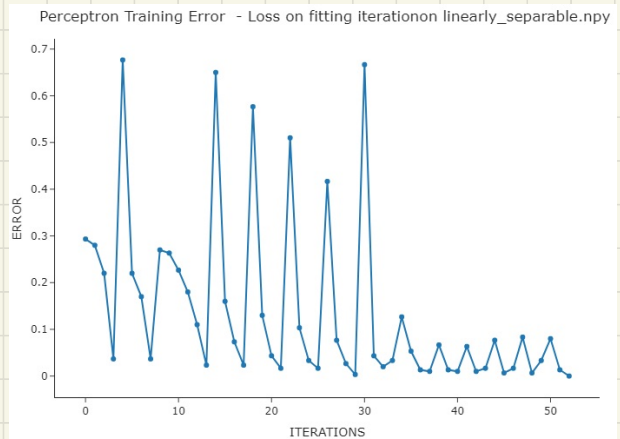
$$n_k = \frac{n_k}{m}$$

$$\hat{n}_{kj}^{MLE} = \frac{\sum_{i=1}^m \mathbb{I}_{y_i=k}(x_{ij})}{n_k}$$



### 3.1 Perceptron Classifier

Based on Lecture 2 and Book



הצ'ור מייצג את האלמנטים  
ה Perceptron.

לפי ההרש אפשר לראות שצורה של נתונים שניתן לפרק

אלו ע'נאית, יש מנת ירידה ב מחס (Misclassification loss)

טזה אומר שכל שיש לך יותר איטרציות המנה תרד

הרש מעספר 52 זה אכס.

בדקו את אכס ע'נאית שלטיוניתם עובד

הצורה טובה ל data שהוא ע'נאית.



• אפשר לראות בסרטון זה שמדובר בסט נתונים שלא ניתן להפרידה ליניארית. • בסרטון ההל מוצגת מסויימ האלגוריתם מדפיס בדפוס קבוע כלומר מזהה הישגים נשארתי ולא משתנה (בפרט היא לא אפס).

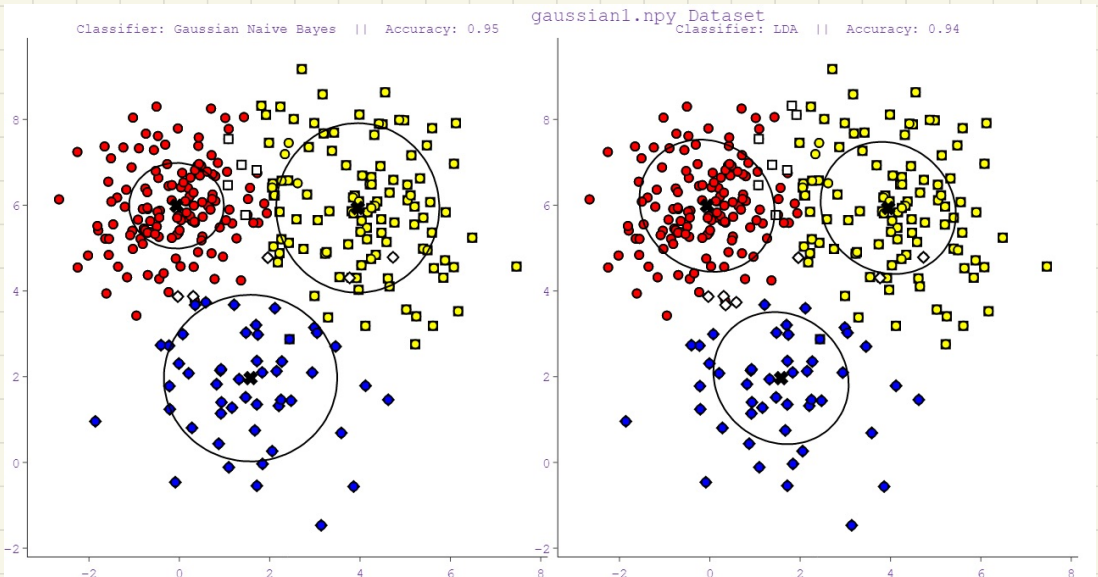
– מכאן אפשר להסיק שיש הבדל בין בעל נתונים ליניארי לליניארי. • בעל נתונים ליניארי – שכן אם הבעל נתונים ליניארי, תמיד נמצא אלגוריתם ליניארי. (האלגוריתם ימשיך לעבוד פיתרון, אבל אין כזה מה שזוהי את הדפוס שיזה שחוזר על עצמו).

## 3.2 Bayes Classifiers

הסרסוס ניתקן לראות GNB / LDA רר dataset  
הראשון.

אכסר פראאר ש ה - GNB משיג 95.3% accuracy  
וגר LDA 94%.

לכן נסיק שהנקודות מבוזרות יחסית בצורה אחידה  
סביב התחלות של כל אחת ששגי החלקות בנראה מתפלגות  
נורמל.



מהרסוס הסן אפשר עראת:

ע- GNB נש' 85.33% accuracy

ע- LDA נש' 97% accuracy

אפשר עראת ש ב גלס יא סז לא תלות ע'נאית, נ' הגלס  
מתפבר ברק ע'נאית (אשר ענדיון), ועכן אפשר עה'ג  
ש מודל LDA יור מדייק מהמודל GNB  
גלס ש- GNB מניה א' תלות בין גפ'צרים ← שזה מה  
טפומז ביכולת הח'צוי גלו. ו- LDA מניה תלות ע'נאית, כלומר  
שה גלס ניתן ערברזה ע'נאית.

